2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 36

Ferreyra, Elian

Paredes, Valentin

Rivolta, Matias

1. Introducción

El fenómeno del alquiler temporal a través de plataformas digitales como Airbnb ha transformado el mercado inmobiliario urbano en las principales capitales del mundo. En la Ciudad Autónoma de Buenos Aires (CABA), esta dinámica ha mostrado un crecimiento acelerado impulsado por el turismo internacional y distorsiones macroeconómicas locales. El objetivo central de este trabajo práctico es caracterizar la oferta de Airbnb en Buenos Aires a partir del dataset *Inside Airbnb* (2026), identificando patrones de concentración de propiedad, estructuras de precios y dinámicas de independencia en el hospedaje.

El conjunto de datos proviene del proyecto independiente *Inside Airbnb*, el cual realiza tareas de web scraping público sobre la plataforma para proporcionar métricas transparentes acerca del impacto del alquiler a corto plazo en las comunidades locales. El dataset original consta de 29,685 registros y 90 variables descriptivas del alojamiento, el anfitrión, la ubicación geográfica, los precios y el comportamiento de las reseñas.

Durante la etapa de inspección inicial se identificaron problemas severos de redundancia de datos y valores faltantes. Para corregir estas deficiencias, se aplicó una limpieza de datos en Python dentro de una Jupyter Notebook:

1. Eliminación de 13 columnas con 100% de valores nulos (e.g., neighborhood_overview, calendar_updated, license).
2. Descarte de 7 variables no informativas o compuestas por enlaces web (scrape_id, listing_url, host_picture_url, etc.).
3. Antes del inicio de cada Hipótesis, se tratan los datos faltantes, los outliers, o datos erróneos.

La notebook se organiza de la siguiente manera: la Sección 1 detalla el Análisis Exploratorio de Datos (EDA) y las decisiones de limpieza; la Sección 2 aborda las hipótesis que tuvimos que construir como grupo, desde la elección de los datos de valor, hasta la validación mediante el uso de test de hipótesis; y la Sección 3 aborda lo mismo, pero enfocado en las hipótesis planteadas por el enunciado. En cada sección podemos encontrar:

1. Creación de data frames propios tomando las columnas de valor para la hipótesis a abordar.
2. Limpieza de datos erróneos, faltantes y/o outliers extremos.
3. Visualización de los datos iniciales
4. Uso de test de hipótesis para validar o rechazar estas mismas.

2. Análisis exploratorio de los datos

Se exploró el dataset ya depurado de nulos y se encontraron varias columnas que, en primera instancia, no nos aportan información de nada. Las columnas son:

- ‘Listing_url’: Es el link de airbnb.
- ‘Scrape_id’: Es el identificador de scrapeo.
- ‘Picture_url’: Es el link a la imagen de la propiedad.
- ‘host _url’: Es el link al perfil del anfitrión.
- ‘Host_picture_url’: Es el link a la foto de perfil del anfitrión.
- ‘Host_has_profile_pic’: Indica si el usuario tiene o no foto de perfil.
- ‘Host_thumbnail_url’: Es el link a la foto reducida del anfitrión.
- ‘Host_profile_url’: Es otro link hacia el perfil del anfitrión.

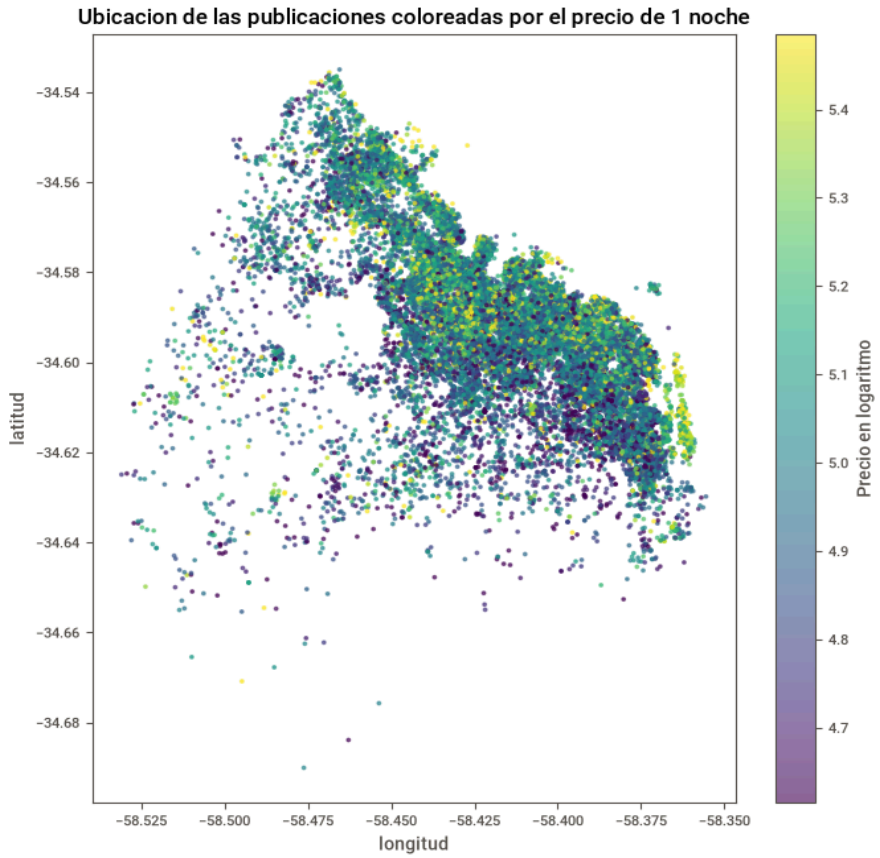
Con el análisis inicial, notamos que hay varios atributos los cuales están muy condicionados por outliers, entendemos que esto sucede por 2 cuestiones principales, airbnb es una plataforma libre, es decir no te condiciona al listar una propiedad, en cuanto a precio u otras consideraciones, pero además, lo que sucede es que el dataset consta de alquileres en CABA, y esto nos pie a entender a que hay muchas variables en cuanto al barrio o zona donde está ubicada la propiedad.

Un ejemplo claro de cómo se basa el mercado de airbnb, es la siguiente tabla, donde vemos que tipos de alojamientos son los más comunes de encontrar.

Tipo de Alojamiento	Anuncios	Porcentaje
Entire home/apt	26,790	90.25%
Private room	2,616	8.81%
Hotel room	141	0.47%
Shared room	138	0.46%

Acá tenemos de primera mano un indicio de que airbnb está enfocado, en la mayoría de los casos, en alquileres de departamentos o casas.

Otra cuestión que nos resultó interesante, era poder observar gráficamente cómo se distribuyen en la ciudad los alquileres y como el precio podría llegar a estar condicionado por la zona.
Esto lo pudimos hacer gracias a los datos de coordenadas dentro del dataset, llamados 'longitude' y 'latitude', los cuales nos indican la posición geográfica de la propiedad en forma de coordenadas.
Lo primero que hicimos fue normalizar los precios al logaritmo en base 10, y además recortamos las colas 0.05 y 0.95



Esto, junto a la cantidad de publicaciones por barrio calculada en la notebook, nos dice claramente que la oferta de alquileres de airbnb recae en su mayoría entre palermo, recoleta, san nicolás y retiro, ocupando entre las 4, más de 17000 publicaciones. También encontramos como punto caliente al barrio de puerto madero, que a pesar de no contar con tantas propiedades, es una zona que concentra precios más elevados

3. Hipótesis realizadas por el grupo

3.1 Hipótesis 1

Definición de la hipótesis

La mayoría de la oferta de Airbnb en Buenos Aires está orientada al turismo de corta estancia, concentrando más del 70% de sus publicaciones con estancia mínima no superior a las 3 noches. Esta será nuestra hipótesis alternativa

Estrategia de abordaje

Para evaluar esta hipótesis primero se identificaron las columnas que entraban en juego para el análisis adecuado, en este caso, solo nos interesa la variable 'minimum_nights' para poder conocer que la cantidad de noches mínimas sea realmente menor a 3. Se creó un dataframe nuevo llamado df_h1 el cual contiene solo la columna deseada, y además limpiamos la variable de posibles nulos. Se recurre al uso de estadísticas como la media y la mediana. Mostramos gráficamente lo que estaba pasando, y por último, abordamos la hipótesis de manera estadística.

Resultados obtenidos y discusión

Se recurre a un test t de proporciones, ya que estamos comparando dos proporciones de la muestra en 2 grupos, encontramos que el 77,95% de las publicaciones con con mínimo de noches menor a 3 noches:

- Publicaciones con un mínimo de noches menor a 3 días: **23,136 publicaciones**.
- Porcentaje de la oferta total: **77.95%**.

La hipótesis nula ha sido RECHAZADA. Esto da como resultado, que nuestra hipótesis alternativa inicial es VERDADERA. Interpretamos este resultado de la siguiente manera, airbnb, en buenos aires, está más orientado a alquileres turísticos, generalmente de feriados o días no laborales. Esto no quita que hay más opciones de estadía larga o mediana, pero que en Buenos Aires, dentro de la aplicación de airbnb, son las que menos.

3.2. Hipótesis 2

Definición de la hipótesis

Los alojamientos gestionados por superhost obtienen, en promedio, reseñas con calificaciones significativamente más altas que aquellos anfitriones que no lo son.

Estrategia de abordaje

Se identificaron las columnas que nos interesaban para el análisis y se limpiaron los nulos, estas columnas son 'host_is_superhost' la cual nos indica para cada publicación, si su anfitrión es un superhost (usuario con reconocimiento Airbnb), y la columna 'review_scores_rating' que nos indica la calificación del establecimiento en una escala continua del 1 al 5. Se estandarizó a 2 tipos de anfitrión, superhost y estándar, para no utilizar el booleano original.

Resultados obtenidos y discusión

Se toma como hipótesis alternativa a la hipótesis planteada al inicio.
Se probaron los supuestos de normalidad y homocedasticidad, y en ambos el p-valor fue menor a 0.001, por esto, ambos supuestos fueron rechazados, y se recurre a Kolmogorov-smirnov para corroborar, este también arrojó un p-valor < 0.001, por ende, se recurre a un test no-paramétrico y a un test t con corrección de Welch:

- Media/Mediana Superhost: **4.88 / 4.91**
- Media/Mediana Estándar: **4.70 / 4.80**
- Test t con corrección de Welch: **p < 0.05**
- Mann-Whitney U test p-valor: **p < 0.05**

La hipótesis nula es RECHAZADA. Por esto, la hipótesis alternativa planteada al comienzo, es VERDADERA. Encontramos que aquellos usuarios que son superhost, realmente son quienes reciben mejores calificaciones. Esto explica el significado o la validez del estatus "Superhost", entendemos que los espacios gestionados por estos anfitriones, son espacios de una calidad superior, en tanto físico como en el trato del anfitrión.

3.3 Hipótesis 3

Definición de la hipótesis

A igual capacidad, tipo de alojamiento y barrio, los alojamientos que exigen estadías mínimas más largas cobran, en promedio, un precio por noche significativamente menor que aquellos que permiten estadías cortas.

Estrategia de abordaje

Se trabajó sobre la base limpia de nulos y sin outliers de precio (filtrados mediante rango intercuartílico IQR), incorporando al análisis la columna 'minimum_nights', la cual nos indica la cantidad mínima de noches exigida para reservar cada publicación. Para reflejar las modalidades de uso del mercado, se agrupó esta variable en una nueva columna categórica llamada 'estadia' con 3 niveles: estadía corta (1 a 6 noches, tomada como categoría base de comparación), estadía media (7 a 29 noches) y estadía larga (30 noches o más). Además, se incluyeron 'accommodates', 'room_type' y 'neighbourhood_cleansed' (barrio) como controles para comparar propiedades equivalentes entre sí.

Resultados obtenidos y discusión

Se toma como hipótesis alternativa a la hipótesis planteada al inicio. Se ajustó una regresión lineal múltiple (OLS) explicando el precio según el tipo de estadía mínima y las variables de control. Se probaron los supuestos correspondientes: el cálculo de VIF dio valores cercanos a 1 (sin multicolinealidad), el estadístico de Durbin-Watson dio cercano a 2 (cumpliendo independencia de los errores), y se revisaron la homocedasticidad y normalidad mediante gráfico de residuos, Q-Q plot y test de Jarque-Bera ($p < 0.001$), contando con más de 20.000 registros que aseguran la solidez de los estimadores:

- Categoría de referencia: Estadía corta (1 a 6 noches)
- Estadía media (7 a 29 noches):
    - Coeficiente negativo (menor precio por noche) / Test t p-valor: **$p < 0.05$**
- Estadía larga (30 noches o más):
    - Coeficiente negativo (descuento aún mayor) / Test t p-valor: **$p < 0.05$**
- Significancia global del modelo (Test F): p-valor: **$p < 0.001$**

La hipótesis nula es RECHAZADA. Por esto, la hipótesis alternativa planteada al comienzo, es VERDADERA. Encontramos que los alojamientos que piden estadías mínimas de una semana o de un mes cobran efectivamente una tarifa por noche más baja que los alquileres de pocos días, aun teniendo la misma capacidad, formato y ubicación. Esto explica la lógica comercial de los anfitriones: al asegurarse una ocupación estable por más tiempo y tener menor rotación, compensan al huésped con un descuento en el precio diario.

4. Hipótesis planteadas por la cátedra

4.1 Hipótesis 4

Definición de la hipótesis

Más del 60% de la oferta la controlan agencias multipropiedad, no personas alquilando su propio hogar. Esta será nuestra hipótesis alternativa

Estrategia de abordaje

Para abordar esta hipótesis, tuvimos una discusión sobre a qué llamar agencia multipropiedad. Terminamos decidiendo por emplear el término utilizado por Inside Airbnb, el cual toma como multi-listing a todo anfitrión que cuente con 2 o más propiedades en alquiler. Por esto, tomamos las columnas 'host_id' para conocer a cada anfitrión y la columna 'calculated_host_listings_count' que es un cálculo realizado sobre la cantidad de propiedades publicadas de cada anfitrión. Separamos en 2 grupos, los anfitriones con una sola propiedad, y los anfitriones multipropiedad.

Resultados obtenidos y discusión

Encontramos en primera instancia que la cantidad de publicación hechas por host multipropiedad era de 18877, esto ya nos dio un indicio de que la hipótesis podría ser verdadera. Se recurre a un método gráfico de barras para notar esta diferencia.

Por último, se aplicaron los test correspondientes, se optó por un test t de proporciones, tomando como hipótesis nula un porcentaje de 60%.

- Porcentaje de publicaciones por agencias: **63,6%**.
- Porcentaje de publicaciones por particulares: **36,4%**.
- Test t de proporciones: **$p < 0.05$**

La hipótesis nula ha sido RECHAZADA. Por esto, nuestra hipótesis alternativa planteada al inicio se da por VERDADERA. Si bien, el método que utilizamos para determinar si un anfitrión es o no una agencia, no es el más adecuado, creemos que es el más certero. Con este resultado entendemos que si bien Airbnb es un sitio donde cualquiera puede ofrecer una propiedad en alquiler, es más propenso a que sea utilizado por agencias, para tener una mayor visibilidad.

3.5. Hipótesis 5

Definición de la hipótesis

Alquilar un espacio entero cuesta, en promedio, más del doble que alquilar una habitación privada. Esta será nuestra hipótesis alternativa.

Estrategia de abordaje

Para abordar esta hipótesis, primero elegimos las variables correspondientes a analizar, tomamos las variables ‘room_type’ que nos indica que tipo de propiedad en alquiler es, y la variable ‘price_quote_price_per_night’ la cual nos indica cuanto es el valor de una noche en la propiedad, utilizando como referencia la columna ‘price’, la cual indica lo mismo pero como un string. Corroboramos la presencia de nulos y outliers, para una posterior limpieza, y vemos si existen duplicados. Utilizamos métodos gráficos tanto boxplot como barras.

Resultados obtenidos y discusión

Con los outliers borrados, ya que generaban ruido en la media, se pasó a chequear los supuestos de normalidad y homocedasticidad, ambos fueron rechazados, por esto, pasamos a utilizar el test de la mediana para proporciones

- Mediana de espacios enteros: **99670.63**
- Mediana (doble) de habitaciones privadas: **96232**
- Mediana global: **99442**
- Test de la mediana: **p=0.077, p>0.05**

No se rechaza la hipótesis nula, ya que no se encontró evidencia suficiente para afirmar que las medianas de los grupos son diferentes, por esto, concluimos en que, no necesariamente un alquiler de espacio entero, cuesta más del doble que el de una habitación privada. Interpretamos esto como algo natural del mercado de alquileres, ya que no todos están en la misma zona o, incluso con las mismas comodidades.

4.3 Hipótesis 6

Definición de la hipótesis

A igual capacidad, un alojamiento se alquila a un precio significativamente más alto si brinda mayor independencia a los huéspedes: una cama por persona, mayor cantidad de baños por huésped y posibilidad de reserva automática.

Estrategia de abordaje

Se identificaron las columnas que nos interesaban para el análisis y se limpiaron los nulos, estas columnas son 'price' (pasada a formato numérico como 'precio'), 'accommodates' (capacidad de huéspedes), 'beds' (cantidad de camas) y 'bathrooms' (cantidad de baños), junto con 'room_type' (tipo de alojamiento) y 'neighbourhood_cleansed' (barrio) utilizadas como variables de control. La columna 'instant_bookable' (reserva automática) se encontró completamente vacía en el dataset original, por lo que no pudo ser utilizada. Dado que el nivel de independencia no viene expresado de forma directa, se crearon las variables 'camas_por_huesped' (beds / accommodates) y 'banos_por_huesped' (bathrooms / accommodates), descartando registros anómalos con más de 2 camas o baños por persona. Por último, se limpiaron los valores extremos del precio utilizando el rango intercuartílico (IQR).

Resultados obtenidos y discusión

Se toma como hipótesis alternativa a la hipótesis planteada al inicio. Se ajustó un modelo de regresión lineal múltiple (OLS) sobre el precio controlando por capacidad, tipo de alojamiento y barrio. Se probaron los supuestos del modelo: se verificó la ausencia de multicolinealidad mediante el VIF (todos los valores < 1.4), la independencia de los errores mediante el estadístico de Durbin-Watson (DW cercano a 2.0), la homocedasticidad con el gráfico de residuos vs. predichos y la normalidad con Q-Q plot y el test de Jarque-Bera ($p < 0.001$). Si bien la normalidad estricta fue rechazada por asimetría en los precios más altos, el gran tamaño de la muestra (> 20.000 observaciones) respalda la validez de las pruebas t de los coeficientes:

- Baños por huésped (banos_por_huesped): Coeficiente positivo / Test t p-valor: **$p < 0.05$**
- Camas por huésped (camas_por_huesped): Coeficiente negativo (no incrementa el precio)
- Capacidad (accommodates): Coeficiente positivo / Test t p-valor: **$p < 0.05$**
- Reserva automática (instant_bookable): Sin datos en la base (**100% nulos**)

La hipótesis nula es RECHAZADA parcialmente (sólo para la proporción de baños por huésped). Por esto, la hipótesis alternativa planteada al comienzo, es PARCIALMENTE VERDADERA. Encontramos que, a igual capacidad, tipo de propiedad y barrio, contar con más baños por persona encarece de forma significativa el precio por noche. Por el contrario, una mayor cantidad de camas por huésped no se traduce en un precio mayor, mientras que la reserva automática no pudo evaluarse por falta de datos.

4. Conclusiones

El análisis integral del conjunto de datos de *Inside Airbnb (2026)* sobre la Ciudad Autónoma de Buenos Aires permitió trascender las percepciones intuitivas para construir una radiografía empírica, rigurosa y certera sobre el funcionamiento del mercado de alquileres temporales en la capital argentina. A lo largo del proyecto, la ciencia de datos no funcionó meramente como una caja de herramientas matemáticas, sino como un lente crítico para contrastar hipótesis comerciales y socioeconómicas frente a la realidad cruda de los datos.

4.1 La fisonomía del mercado: profesionalización y concentración urbana

El primer hallazgo contundente es la desmitificación de Airbnb como una plataforma de "economía colaborativa" entre particulares que rentan una habitación vacía de su hogar. El mercado porteño está profundamente concentrado y profesionalizado:

- **Predominio del espacio entero:** Más del **90,2%** de las publicaciones corresponden a departamentos o casas completas, relegando las habitaciones privadas a un marginal 8,8%.
- **El peso de las agencias y multi-anfitriones:** La validación de la Hipótesis 4 confirmó que el **63,6% de la oferta** está en manos de anfitriones con dos o más propiedades. Quienes dinamizan y capitalizan la plataforma son operadores comerciales y agencias de gestión inmobiliaria, no vecinos ocasionales.
- **Geografía del turismo:** La oferta no se distribuye de forma homogénea en el tejido urbano; se concentra intensamente en un corredor estratégico compuesto por Palermo, Recoleta, Retiro y San Nicolás (acumulando más de 17.000 anuncios), con enclaves de alta gama como Puerto Madero, donde los precios escapan a la media de la ciudad.

4.2 Estructura de precios, estancias y el valor de la privacidad

El modelado estadístico bivariado y multivariado reveló con claridad las reglas económicas que rigen la fijación de tarifas:

- **Turismo de rotación rápida:** Confirmando la Hipótesis 1, casi el **78% de la oferta** exige estancias mínimas no mayores a 3 noches, evidenciando un modelo orientado al visitante de fin de semana, escapadas cortas o turismo transitorio regional e internacional.
- **El descuento por permanencia:** Al controlar por capacidad, formato y barrio (Hipótesis 3), la regresión múltiple demostró una asociación inversa significativa entre el tiempo de estancia y el precio por noche: asegurarse ocupaciones medias (7 a 29 noches) implica una rebaja promedio cercana al **17%**, mientras que contratos mensuales (≥30 noches) conllevan descuentos de alrededor del **30%**. El anfitrión premia la previsibilidad y la reducción de costos de rotación (limpieza, check-in, vacancia), acercándose progresivamente a las reglas del alquiler residencial clásico.

- **Calidad y reputación:** La etiqueta de *Superhost* (Hipótesis 2) no es un mero adorno visual de marketing: sus alojamientos sostienen medianas de calificación significativamente superiores (4,91 vs. 4,80), respaldadas por pruebas no paramétricas ($p<0,05$), lo que valida que el algoritmo de la plataforma reconoce un diferencial palpable de servicio y confort.
- **¿Qué comodidades cotizan de verdad?:** El análisis de la independencia (Hipótesis 6) dejó una lección central: **la privacidad sanitaria cotiza, el hacinamiento no**. A igual capacidad y ubicación, un incremento en la proporción de baños por huésped encarece significativamente la noche, mientras que sumar más camas por persona no incrementa el valor (e incluso puede penalizar al asemejarse a la tipología de albergue o hostel).

4.3 La disciplina estadística frente al sentido común

Uno de los aprendizajes más valiosos del trabajo surgió en la Hipótesis 5 (alquiler de espacio entero vs. habitación privada). La creencia popular de que un departamento entero cuesta *más del doble* que una habitación privada no pudo sostenerse con significancia estadística ($p=0,077$ en el test de medianas tras controlar valores atípicos). Este resultado enseña que las medias globales suelen estar distorsionadas por la dispersión geográfica y la heterogeneidad de comodidades: una habitación privada de alta categoría en Recoleta puede rivalizar en precio con un monoambiente modesto en barrios menos céntricos.

Asimismo, la auditoría metodológica —el rechazo sistemático de normalidad y homocedasticidad mediante Shapiro-Wilk, Jarque-Bera y Levene, el tratamiento de valores extremos mediante rango intercuartílico (IQR), y la corrección de errores agrupados por anfitrión— puso en evidencia que trabajar con datos reales de plataformas abiertas exige abandonar los supuestos de manual y adoptar técnicas robustas (pruebas de Welch, Mann-Whitney U, regresiones logarítmicas con VIF controlado).

4.4 Reflexión de cierre

En conclusión, la oferta de Airbnb en Buenos Aires se comporta como un mercado maduro, altamente turístico y dolarizado de facto, dominado por actores que administran carteras de propiedades completas y aplican estrategias de precios racionales según la duración de la estadía y el nivel de confort. Para la Ciudad Autónoma de Buenos Aires, estos hallazgos ilustran con solidez cuantitativa las tensiones contemporáneas entre el desarrollo del turismo receptivo y la presión sobre el acceso a la vivienda residencial permanente.

Referencias

Inside Airbnb. *Data Bank and Methodology for Short-Term Rental Analytics*. Recuperado de https://insideairbnb.com/get-the-data/
Cuaderno de ejecución Jupyter: *Análisis Exploratorio y Modelado de Hipótesis Airbnb CABA*